Contenido

ANÁLISIS DEL PROYECTO 2
LIMPIEZA DE DATOS (Python) 2
Fase 1: Carga de datos 2
FASE 2: INSPECCIÓN INICIAL 2
FASE 3: LIMPIEZA Y ESTANDARIZACIÓN 3
FASE 4: Validaciones Adicionales 4
FASE 5: Creación del dataset limpio 6
FASE 6: FUNCIÓN PRINCIPAL 6
ANÁLISIS ESTADISTICO (PYTHON) 7
Tendencia Temportal de Ethanol_All_Drinks_Gallons_Per_Capita 7
Distribución por décadas 8
Matriz de correlaciones 9
INTERVALO DE CONFIANZA 10
POWERBI 10
Comparativa cerveza, vino y Licor (spirit) 11
ANÁLISIS DE CERVEZA 12
Análisis de vino 13
ANÁLISIS DE LICOR 15

ANÁLISIS DEL PROYECTO

LIMPIEZA DE DATOS (Python)

Fase 1: Carga de datos

El primer paso es la carga de datos e importar las librerías necesarias para realizar el código. Esta función se encarga de importar el archivo CSV original utilizando pandas.read_csv(). Además, muestra por pantalla el número de filas cargadas para verificar que la lectura se ha realizado correctamente

```python
# ================================================================
# PROCESAMIENTO Y LIMPIEZA DEL DATASET DE CONSUMO DE ALCOHOL (NIAAA)
# ================================================================

import pandas as pd

# ----------------------------------------------------------------
# 1. Función: Cargar datos
# ----------------------------------------------------------------

def load_data(path: str) -> pd.DataFrame:
    """Carga el dataset original desde un archivo CSV."""
    df = pd.read_csv(path)
    print(f"Dataset cargado correctamente. Filas: {len(df)}")
    return df
```

Resultado:

```
t/main.py
Dataset cargado correctamente. Filas: 2632
```

FASE 2: INSPECCIÓN INICIAL

En esta fase se realiza una exploración preliminar del dataset para comprender su estructura:

- Se muestran las primeras filas del archivo.
- Se imprime la información general del DataFrame (df.info()), incluyendo tipos de datos.
- Se contabilizan los valores nulos por columna.

Código:

```python
# ---------------------------------------------------------------
# 2. Función: Inspección inicial
# ---------------------------------------------------------------

def inspect_data(df: pd.DataFrame) -> None:
    """Muestra información básica del dataset."""
    print("\n--- Primeras filas ---")
    print(df.head())

    print("\n--- Información general ---")
    df.info()

    print("\n--- Valores nulos ---")
    print(df.isnull().sum())
```

Resultado:

```
--- Primeras filas ---
    state state_name  year  ethanol_beer_gallons_per_capita  ...  number_of_beers  number_of_glasses_wine  number_of_shots_liquor  number_of_drinks_total
0  alabama    Alabama  1977                             0.97  ...         229.9259                 23.8140                170.2514                409.6000
1  alabama    Alabama  1978                             0.95  ...         225.1852                 23.8140                176.4801                409.6000
2  alabama    Alabama  1979                             0.96  ...         227.5556                 23.8140                170.2514                405.3333
3  alabama    Alabama  1980                             0.95  ...         225.1852                 31.7519                153.6415                396.8000
4  alabama    Alabama  1981                             1.00  ...         237.0370                 37.7054                151.5653                407.4667

[5 rows x 11 columns]

--- Información general ---
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2632 entries, 0 to 2631
-null   float64
 7   number_of_beers                2632 non-null   float64
 8   number_of_glasses_wine         2632 non-null   float64
 9   number_of_shots_liquor         2632 non-null   float64
 10  number_of_drinks_total         2632 non-null   float64
dtypes: float64(8), int64(1), object(2)
memory usage: 226.3+ KB

--- Valores nulos ---
state                                  0
state_name                             0
year                                   0
ethanol_beer_gallons_per_capita        0
ethanol_wine_gallons_per_capita        0
ethanol_spirit_gallons_per_capita      0
ethanol_all_drinks_gallons_per_capita  0
number_of_beers                        0
number_of_glasses_wine                 0
number_of_shots_liquor                 0
number_of_drinks_total                 0
```

FASE 3: LIMPIEZA Y ESTANDARIZACIÓN

Esta función aplica dos operaciones fundamentales:

1. Eliminación de duplicados: Se detectan y eliminan filas duplicadas mediante df.drop_duplicates(). Esto garantiza que no existan registros repetidos que puedan sesgar el análisis.

2. Estandarización de nombres de columnas: Se normalizan los nombres de las columnas aplicando:

    - str.strip() → elimina espacios sobrantes

- str.title() → convierte cada palabra a formato Título

Código:

```python
# ------------------------------------------------------------------
# 3. Función: Limpieza y estandarización
# ------------------------------------------------------------------

def clean_data(df: pd.DataFrame) -> pd.DataFrame:
    """Limpia duplicados y estandariza nombres de columnas."""

    # Eliminar duplicados
    duplicates = df.duplicated().sum()
    print(f"\nDuplicados detectados: {duplicates}")
    df = df.drop_duplicates()

    # Estandarizar nombres de columnas
    df.columns = df.columns.str.strip().str.title()

    print("\nColumnas estandarizadas:")
    print(df.columns.tolist())

    return df
```

Resultado:

```
Duplicados detectados: 0

Columnas estandarizadas:
['State', 'State_Name', 'Year', 'Ethanol_Beer_Gallons_Per_Capita', 'Ethanol_Wine_Gallons_Per_Capita', 'Ethanol_Spirit_Gallons_Per_Capita', 'Ethanol_All_Drinks
_Gallons_Per_Capita', 'Number_Of_Beers', 'Number_Of_Glasses_Wine', 'Number_Of_Shots_Liquor', 'Number_Of_Drinks_Total']
```

FASE 4: Validaciones Adicionales

Esta función incorpora comprobaciones de coherencia para garantizar la calidad del dataset:

- Validación del tipo de dato en la columna Year: Se verifica que sea numérica, ya que es fundamental para análisis temporales.
- Comprobación de consistencia entre bebidas individuales y total: Si existen las columnas necesarias, se calcula la diferencia entre: Number_Of_Beers + Number_Of_Glasses_Wine + Number_Of_Shots_Liquor y Number_Of_Drinks_Total.

Se muestra la desviación media para detectar posibles inconsistencias metodológicas del dataset original.

Código:

```python
# ---------------------------------------------------------------
# 4. Función: Validaciones adicionales
# ---------------------------------------------------------------

def validate_data(df: pd.DataFrame) -> None:
    """Realiza comprobaciones básicas de consistencia."""

    # Validar que Year es numérico
    if not pd.api.types.is_numeric_dtype(df["Year"]):
        print("⚠ Advertencia: La columna 'Year' no es numérica.")

    # Validar coherencia entre número de bebidas y total
    required_cols = [
        "Number_Of_Beers",
        "Number_Of_Glasses_Wine",
        "Number_Of_Shots_Liquor",
        "Number_Of_Drinks_Total"
    ]

    if all(col in df.columns for col in required_cols):
        df["check_diff"] = (
            df["Number_Of_Beers"] +
            df["Number_Of_Glasses_Wine"] +
            df["Number_Of_Shots_Liquor"]
        ) - df["Number_Of_Drinks_Total"]

        print("\nDesviación media entre suma de bebidas y total:",
              df["check_diff"].mean())

        df.drop(columns=["check_diff"], inplace=True)
```

Resultado:

```
Desviación media entre suma de bebidas y total: 19.49627990121581
```

La columna *Number_Of_Drinks_Total* no es la suma directa de cervezas, vinos y spirit. Representa el total de “bebidas estándar”, donde cada categoría se convierte a una unidad común basada en su contenido de etanol. Por eso aparece una desviación media positiva: el total sigue una metodología distinta y no debe coincidir con la suma de las bebidas individuales.

FASE 5: Creación del dataset limpio

Una vez completado el proceso de limpieza y validación, el DataFrame resultante se guarda en un nuevo archivo CSV llamado clean_data.csv.

Código:

```
# ------------------------------------------------------------
# 5. Función: Guardar datos limpios
# ------------------------------------------------------------

def save_data(df: pd.DataFrame, path: str) -> None:
    """Guarda el dataset limpio en un archivo CSV."""
    df.to_csv(path, index=False)
    print(f"\nArchivo exportado correctamente: {path}")
```

FASE 6: FUNCIÓN PRINCIPAL

La función main() orquesta todo el pipeline:

1. Carga del dataset original
2. Inspección inicial
3. Limpieza y estandarización
4. Validaciones adicionales
5. Exportación del dataset limpio

Finalmente, el script se ejecuta automáticamente cuando se llama desde la terminal.

Código:

```
# ------------------------------------------------------------
# 6. Función principal
# ------------------------------------------------------------

def main():
    df = load_data("niaaa_apparent_per_capita_consumption_1977_2023.csv")
    inspect_data(df)
    df = clean_data(df)
    validate_data(df)
    save_data(df, "clean_data.csv")


if __name__ == "__main__":
    main()
```

ANÁLISIS ESTADISTICO (PYTHON)

Tendencia Temportal de Ethanol_All_Drinks_Gallons_Per_Capita

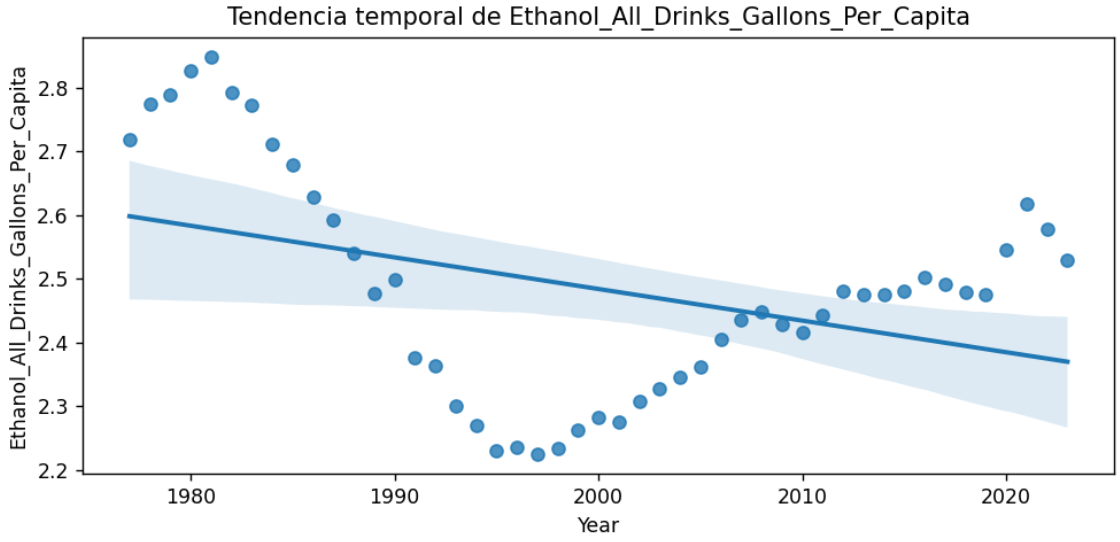

Se estimó una regresión lineal para analizar la evolución del consumo total de etanol per cápita. La gráfica muestra una tendencia descendente significativa, con valores más altos a finales de los años 70 y un descenso progresivo hasta principios de los 2000, seguido de un ligero repunte en la última década. La pendiente negativa del modelo indica que el consumo per cápita ha disminuido en el largo plazo, y el p-value asociado confirma que esta tendencia es estadísticamente significativa. La banda de confianza del 95% refleja la incertidumbre del modelo y valida la consistencia del patrón observado.

Datos de la regresión lineal temporal:

- Coeficiente del año: −0.0050
- p-value: 0.007
- R^2: 0.149

Distribución por décadas

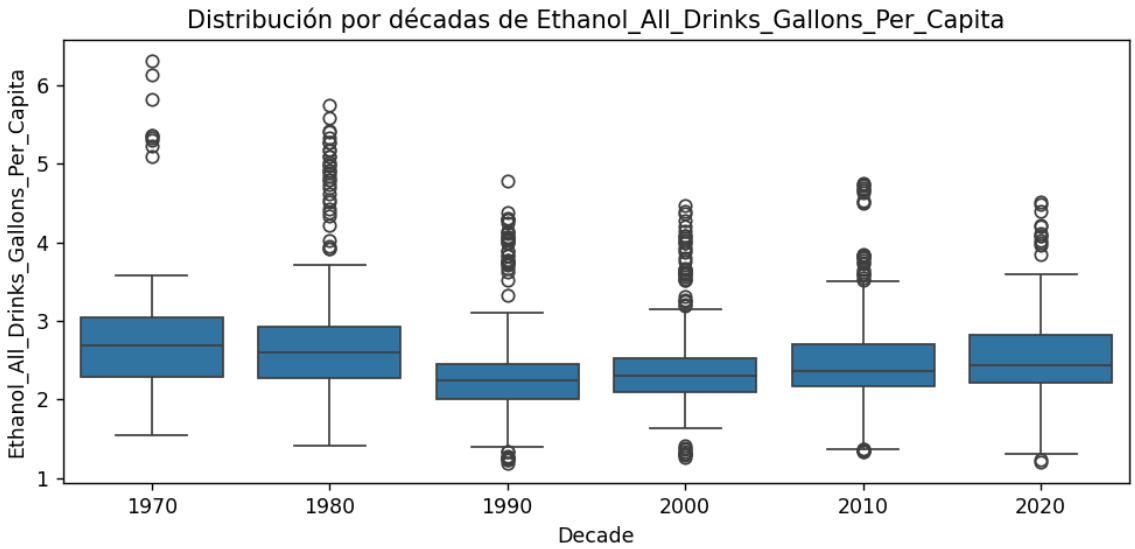

Este gráfico muestra la distribución del consumo total de etanol per cápita en Estados Unidos agrupado por décadas. Cada boxplot representa la variabilidad del consumo dentro de cada periodo, incluyendo mediana, rango intercuartílico y valores atípicos.

El análisis revela que:

- Las décadas de 1970 y 1980 presentan los niveles más altos de consumo, con medianas superiores al resto de periodos.
- A partir de los años 90 se observa un descenso claro, con una reducción notable tanto en la mediana como en la dispersión del consumo.
- En las décadas de 2000 y 2010 el consumo se estabiliza en niveles más bajos, mostrando menor variabilidad entre estados y años.
- La década de 2020 muestra un ligero repunte, aunque todavía por debajo de los niveles históricos más altos.
- El ANOVA realizado confirma que las diferencias entre décadas son estadísticamente significativas ($p < 0.05$), lo que indica que los cambios observados no se deben al azar.

En conjunto, esta gráfica evidencia una transición estructural en los patrones de consumo de alcohol, con un descenso sostenido desde finales del siglo XX y una estabilización en niveles más moderados en las últimas décadas.

Datos:

- F-statistic: 38.096
- p-value: < 0.001

Matriz de correlaciones

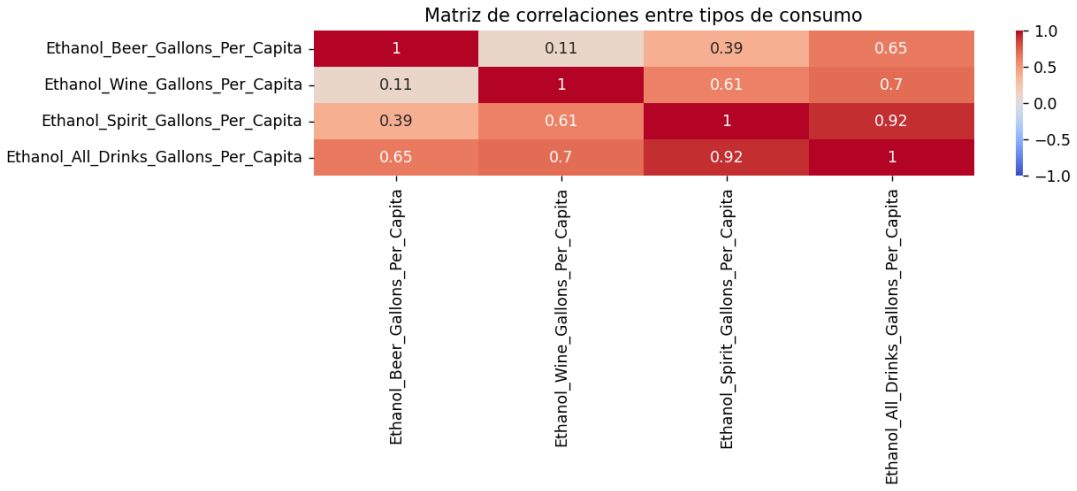

La matriz de correlaciones muestra la relación estadística entre los distintos tipos de consumo de alcohol per cápita en Estados Unidos: cerveza, vino, bebidas spirit y el total de etanol consumido. Cada valor representa el coeficiente de correlación de Pearson, que mide la fuerza y dirección de la relación entre variables (−1 indica correlación negativa perfecta, +1 correlación positiva perfecta).

Principales resultados:

- El consumo total de etanol per cápita está fuertemente correlacionado con las bebidas spirit ($r \approx 0.92$), lo que sugiere que este tipo de bebida tiene el mayor peso en el consumo global.
- El vino presenta una correlación moderada con el total ($r \approx 0.70$), indicando un patrón de consumo parcialmente independiente.
- La cerveza muestra la correlación más baja con el total ($r \approx 0.65$), reflejando una mayor variabilidad regional y temporal en su consumo.
- Las correlaciones entre tipos de bebida son todas positivas, lo que implica que los estados con mayor consumo de una categoría tienden también a consumir más de las otras, aunque en distinta proporción.

El heatmap incluido permite visualizar la intensidad de estas relaciones: los tonos más cálidos representan correlaciones más altas. En conjunto, este análisis evidencia que el consumo total de alcohol está dominado por las bebidas spirit, mientras que el vino y la cerveza contribuyen de forma más moderada y heterogénea.

INTERVALO DE CONFIANZA

Se estimó el intervalo de confianza al 95 % para el consumo total de etanol per cápita:

- Media: 2.4838
- IC 95 %: [2.4607, 2.5069]

Interpretación: El intervalo muestra una variabilidad reducida en el consumo medio nacional, lo que sugiere estabilidad en los niveles actuales. Este rango permite contextualizar los cambios observados y confirmar que las variaciones recientes se mantienen dentro de los límites esperados.

POWERBI

Cuando cargamos los datos, al tener los números décimales separados por "." PowerBi no me reconocía los números. Por ello, en PowerQuery hemos sustituido todos los "." por "," y los hemos convertido a números decimal. Una vez con estos pasos, hemos cargados los valores. Procedemos a hacer gráfico y análisis.

El dataset del NIAAA define el "total" como el consumo de alcohol convertido a etanol puro, mientras que cerveza, vino y licor están expresados en volumen físico de cada bebida. Esto significa que el total no es la suma directa de las tres categorías (como hemos mencionado al principio), sino un cálculo estandarizado basado en equivalentes de etanol. Esta diferencia metodológica explica la desviación observada y evita interpretaciones erróneas al comparar métricas que no están en la misma unidad.

Comparativa cerveza, vino y Licor (spirit)

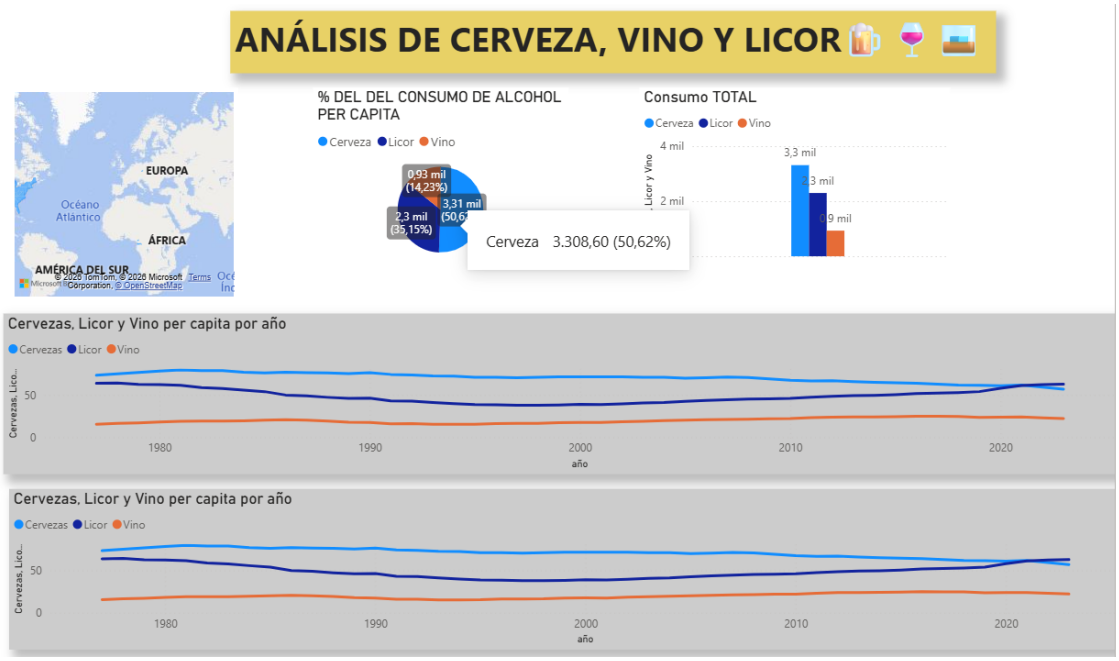

El gráfico circular muestra que el consumo de alcohol per cápita se reparte de forma desigual entre los tres tipos de bebida:

- Cerveza: 50,62%
- Licor: 35.15%
- Vino: 14,23%

Esto indica que la cerveza es, con diferencia, la bebida más consumida en Norteamérica, seguida del licor. El vino queda muy por detrás, lo que sugiere una preferencia cultural clara hacia bebidas de mayor volumen (cerveza) o mayor graduación (licor).

El gráfico de barras refuerza esta tendencia donde el número de unidades total por cada tipo de alcohol es muy superior el de la cerveza.

En los gráficos podemos observar como la evolución ha ido variando y el licor en 2020 ha conseguido superar a la cerveza. Se observa como el consumo de cerveza ha ido decreciendo. Sin embargo, el vino, no hay una elevada fluctuación. La evolución del consumo de cada tipo de alcohol se apreciará más en el análisis individual de cada tipo que vamos a ver a continuación

ANÁLISIS DE CERVEZA

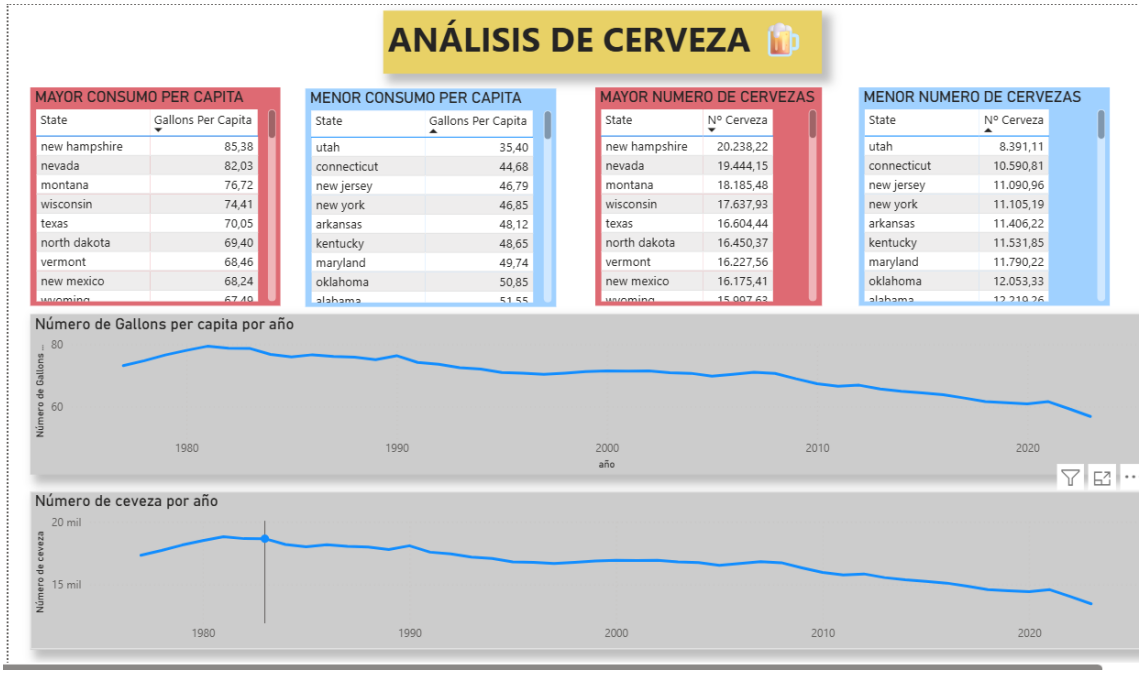

Los datos muestran que el consumo de cerveza per cápita varía significativamente entre estados. Los valores más altos se concentran en:

- New Hampshire (85.38 galones per cápita)
- Nevada (82.03)
- Montana (76.72)
- Wisconsin (74.41)

Estos estados destacan por una cultura de consumo más elevada, posiblemente influida por factores como turismo, clima frío o políticas fiscales favorables.

En el extremo opuesto, los estados con menor consumo son:

- Utah (35.40 galones per cápita)
- Connecticut (44.68)
- New Jersey (46.79)
- New York (46.85)

El caso de Utah es especialmente notable, ya que su consumo es menos de la mitad que el de los estados líderes. Esto se puede explicar por factores culturales y religiosos que desincentivan el consumo de alcohol.

En este caso la unidades per capita y el consumo de unidades coincide, es decir, los estados con mayor consumo per capita son los que más unidades consumen.

El ranking de número total de cervezas por estado coincide casi exactamente con el ranking per cápita, lo que refuerza la consistencia del patrón:

- New Hampshire, Nevada, Montana y Wisconsin vuelven a liderar con cifras superiores a 17.000–20.000 unidades.
- Utah, Connecticut y New Jersey se mantienen como los estados con menor volumen total.

Esto indica que el consumo per cápita y el consumo total están estrechamente alineados, lo que sugiere que la población no distorsiona significativamente los resultados.

El análisis revela una clara división geográfica en el consumo de cerveza dentro de Estados Unidos. Estados como New Hampshire, Nevada y Montana presentan niveles muy elevados tanto en consumo per cápita como en volumen total, mientras que Utah y varios estados del noreste muestran cifras significativamente más bajas. A nivel temporal, el consumo de cerveza ha experimentado una tendencia descendente sostenida durante las últimas cuatro décadas, lo que sugiere un cambio estructural en los hábitos de consumo de alcohol en el país.

ANÁLISIS DE VINO

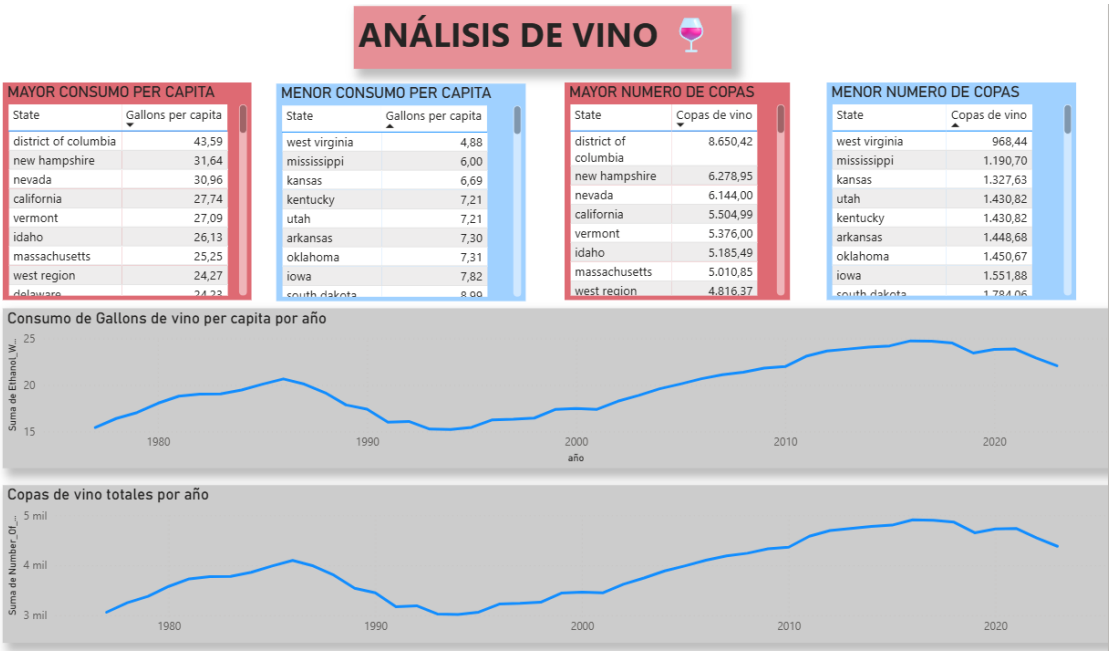

MAYOR CONSUMO PER CAPITA

State	Gallons per capita
district of columbia	43,59
new hampshire	31,64
nevada	30,96
california	27,74
vermont	27,09
idaho	26,13
massachusetts	25,25
west region	24,27
delaware	24,23

MENOR CONSUMO PER CAPITA

State	Gallons per capita
west virginia	4,88
mississippi	6,00
kansas	6,69
kentucky	7,21
utah	7,21
arkansas	7,30
oklahoma	7,31
iowa	7,82
south dakota	8,99

MAYOR NUMERO DE COPAS

State	Copas de vino
district of columbia	8.650,42
new hampshire	6.278,95
nevada	6.144,00
california	5.504,99
vermont	5.376,00
idaho	5.185,49
massachusetts	5.010,85
west region	4.816,37

MENOR NUMERO DE COPAS

State	Copas de vino
west virginia	968,44
mississippi	1.190,70
kansas	1.327,63
utah	1.430,82
kentucky	1.430,82
arkansas	1.448,68
oklahoma	1.450,67
iowa	1.551,88
south dakota	1.784,06

El consumo de vino per cápita es significativamente más alto en:

- District of Columbia (43,59galones por persona)
- New Hampshire (31,64)
- Nevada (30,96)

- California (27,74)

Estos estados presentan una cultura de consumo más orientada al vino, posiblemente influida por factores como nivel educativo, poder adquisitivo, y presencia de industrias vinícolas.

Los valores más bajos se encuentran en:

- West Virginia (4,88 galones por persona)
- Mississippi (6)
- Kansas (6,69)
- Oklahoma (7,21)
- Utah (7,21)

Estos estados muestran una baja penetración del vino en los hábitos de consumo, lo que puede estar relacionado con factores culturales, religiosos o económicos.

El ranking por número de copas consumidas refuerza el patrón anterior. Esto indica que el consumo total y el consumo per cápita están alineados, lo que refuerza la fiabilidad del patrón observado.

La gráfica muestra una tendencia ligeramente ascendente en el consumo de vino per cápita desde 1980, aunque con cierta estabilización en las últimas décadas. El número total de copas de vino consumidas también ha aumentado, lo que sugiere una mayor aceptación del vino como bebida habitual en la población.

Este crecimiento puede estar vinculado a:

- Cambios en preferencias hacia bebidas más suaves
- Mayor disponibilidad y variedad de vinos
- Influencia de tendencias gastronómicas y culturales

El análisis revela que el vino tiene una presencia desigual en los hábitos de consumo de alcohol en Estados Unidos. Mientras que estados como District of Columbia y California muestran un consumo elevado tanto en volumen como en frecuencia, otros como West Virginia y Mississippi mantienen niveles muy bajos. A nivel nacional, el consumo de vino ha experimentado un crecimiento sostenido desde 1980, lo que sugiere una evolución cultural hacia bebidas más sofisticadas y moderadas

ANÁLISIS DE LICOR

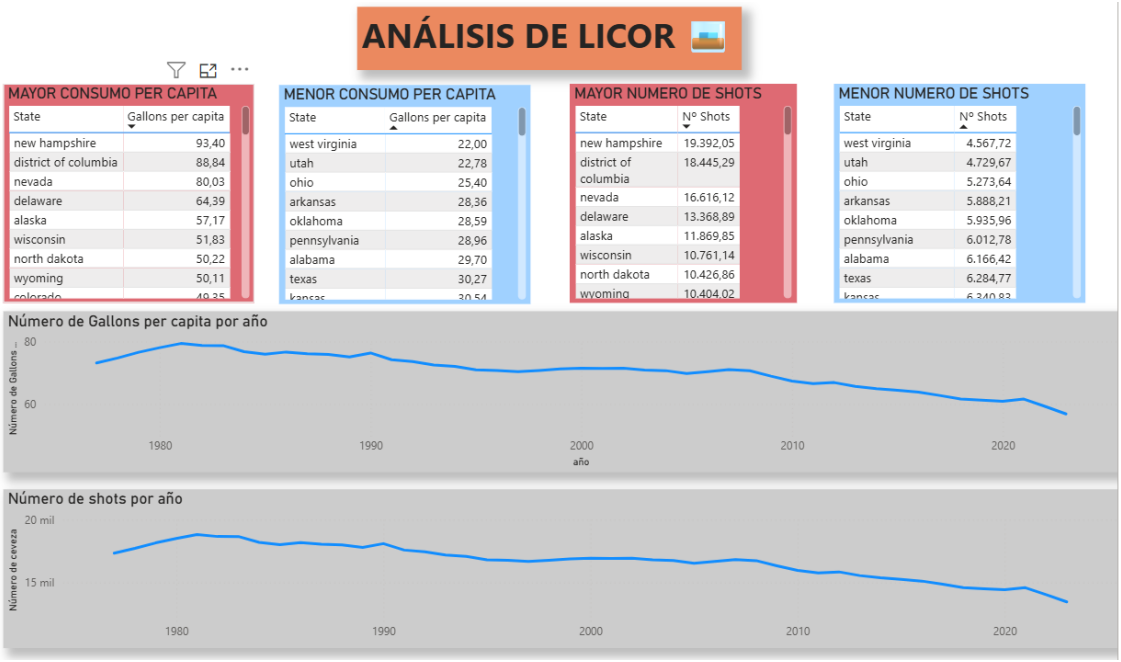

El consumo de licor per cápita muestra diferencias claras entre estados. Los valores más altos se concentran en:

- New Hampshire (93,40)
- District of Columbia (88,44)
- Nevada (80,03)
- Delaware (64,39)
- Alaska (57,17)

Estos estados destacan por un consumo significativamente superior al promedio nacional. En algunos casos, como New Hampshire, esto puede estar relacionado con impuestos más bajos sobre el alcohol, turismo o patrones culturales específicos.

En el extremo opuesto, los estados con menor consumo de licor son:

- West Virginia (22)
- UTAH (22,78)
- Arkansas (25,40)
- Ohio (25,4)
- Oklahoma (28,36)

Utah vuelve a aparecer como el estado con menor consumo, lo que coincide con patrones culturales y religiosos que desincentivan el consumo de alcohol en general.

El ranking del número total de bebidas consumidas mantiene la misma estructura que el consumo per cápita. Esto confirma que el consumo total y el consumo per cápita están alineados, lo que refuerza la consistencia del patrón observado.

La gráfica muestra una tendencia descendente en el consumo de licor per cápita desde los años 80.Aunque hay pequeñas fluctuaciones, la caída es sostenida.

El número total de bebidas también disminuye con el tiempo, lo que indica que la reducción no se debe únicamente a cambios demográficos, sino a un cambio real en los hábitos de consumo.

Este descenso puede estar influido por:

- Mayor concienciación sobre los riesgos del alcohol
- Cambios generacionales en preferencias
- Regulaciones más estrictas
- Sustitución por otras bebidas (vino, cerveza artesanal, bebidas sin alcohol)

El análisis del consumo de licor en Estados Unidos revela una clara división geográfica: estados como New Hampshire, Nevada y el District of Columbia presentan niveles muy elevados, mientras que Utah y varios estados del sur muestran cifras notablemente bajas. A nivel temporal, el consumo de licor ha experimentado una reducción constante durante las últimas cuatro décadas, lo que sugiere un cambio profundo en los hábitos de consumo de alcohol. Este patrón coincide con las tendencias observadas en cerveza y vino, reforzando la idea de una disminución general del consumo de alcohol en el país.